

Redes Neuronales

Alberto Melián Rodríguez y Federico Colleluori

Introducción

En esta práctica el objetivo ha sido crear una red neuronal convolutiva capaz de clasificar un conjunto de datos determinados. Se ha escogido un conjunto de datos proveniente de Kaggle¹, que originalmente consistía en una serie de 26 tipos de bolas diferentes. Se han escogido 5 clases de estas: bolas de béisbol, pelotas de baloncesto, pelotas de playa, bolas de billar y bolas de bolos. Además hay otro conjunto distinto para verificación. Cada clase tiene en torno a 110 elementos, a los que además se les aplica *Data Augmentation*, consistente en cambiar las características de cada imagen (rotándolas, cambiando su brillo...) para obtener lo que esencialmente son nuevos elementos sin mayor esfuerzo, siendo además una buena técnica para evitar el sobreajuste de la red, pues debe tomar en cuenta más orientaciones y es más complicado que “se aprenda las posibilidades de memoria”. Como función de activación de las neuronas utilizaremos la función *relu*, que es sencillamente $relu(x) = x \cdot \frac{sign(x)+1}{2}$. Por su parte, la función de salida que emplearemos es la *softmax*, que es $softmax(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$, que potencia la cercanía de la salida al *one-hot*. Por último, y como es habitual para el *softmax*, como función de pérdida usaremos la entropía categórica cruzada: $d(y, \hat{y}) = -\sum_i y_i \cdot \log(\hat{y}_i)$.

Antes de analizar resultados probaremos varias configuraciones de hiperparámetros de la red y nos quedaremos con la mejor. Después graficaremos la evolución de la precisión y mostraremos la matriz de confusión para analizar los resultados.



Comparativa de hiperparámetros

	Red 1	Red 2	Red 3	Red 4	Red 5	Red 6
Filtros de convolución 1	32	64	8	32	32	32
Tamaño del kernel 1	3	3	3	3	4	3
Tamaño del MaxPooling 1	2	2	2	2	3	3
Filtros de convolución 2	64	128	16	64	64	64
Tamaño del MaxPooling 2	2	2	3	2	2	3
Tamaño del kernel 2	3	3	2	3	4	3
Dropout 1	0,25	0,25	0,25	0,6	0,25	0,25
Filtros de convolución 3	128	256	32	128	128	128
Tamaño del kernel 3	3	3	3	3	4	3
Tamaño del MaxPooling 3	2	2	3	2	2	3
Dropout 2	0,25	0,25	0,25	0,6	0,25	0,25
Tamaño de la capa densa	128	128	128	256	128	128
Dropout 3	0,5	0,5	0,5	0,8	0,5	0,5
Precisión de entrenamiento	0,7681	0,6749	0,7582	0,625	0,875	0,722
Precisión de validación	0,96	0,96	0,96	0,92	1	0,96

¹ <https://www.kaggle.com/gpiosenka/balls-image-classification/version/3>

Finalmente, como tiene la mayor precisión de validación, nos quedamos con la red 5. A juzgar por que los resultados de validación han resultado sensiblemente mayores que los de entrenamiento, podemos asumir que se escogieron las imágenes con dificultades asimétricas entre validación y entrenamiento. No seguimos considerando más modificaciones porque en cada red hemos cambiado un único parámetro con respecto a la red de control (red 1) y solo esta lo ha mejorado. Es interesante que la red 2, que tiene muchos más parámetros que cambiar que el resto y fácilmente podría adolecer el sobreajuste es precisamente a la que menos le ha ocurrido, teniendo el menor porcentaje de aciertos con el conjunto de entrenamiento. Sin duda alguna esto es más que otra cosa, cuestión de azar.

Análisis de Resultados



Los resultados del modelo son, como era esperable, muy buenos, confundiendo solo una pequeña parte de las bolas de billar con las de béisbol y las de baloncesto (es lógico, la bola blanca con banda roja y la bola naranja de billar pueden ser razonablemente parecidas a estas y de bolas de playa con bolas de bolos (hay bolas de bolos muy coloridas)).

Es muy probable que la red haya tenido una cierta cantidad de «suerte» en la validación; porque teniendo un ~88% de éxito en el conjunto de datos de prueba, está claro que un 100% de validación es algo exagerado; aunque es cierto que los resultados son buenos, lo que es de esperar considerando que las imágenes empleadas son razonablemente fáciles de distinguir.